(a) 对话因果大模型 (Chat-LLM) 层叠模块结构



(b) 下三角因果自注意力掩码矩阵 (Causal Mask)

