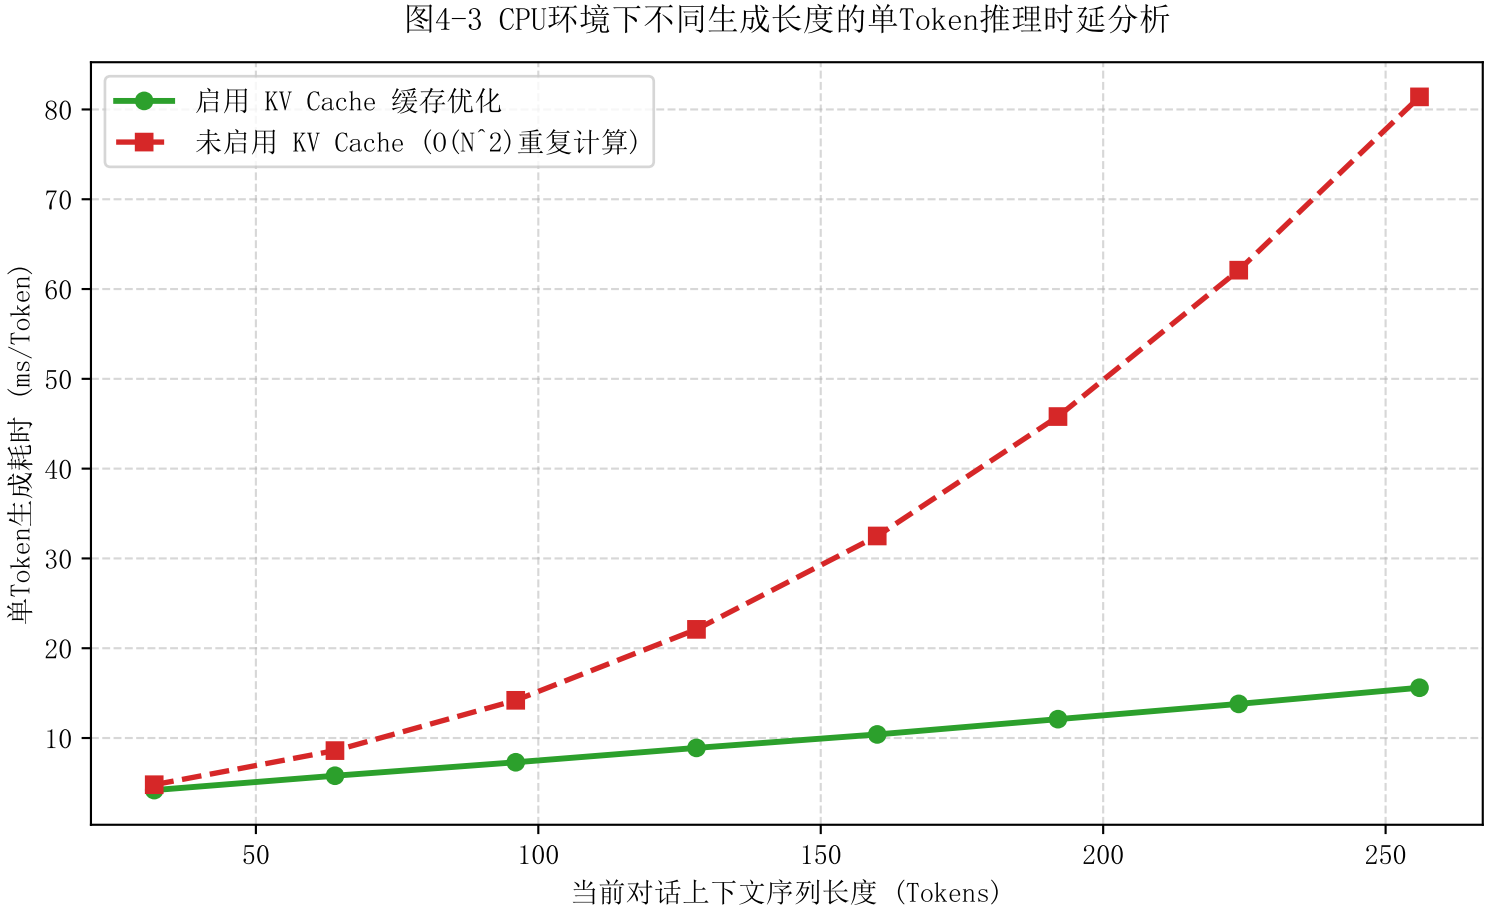
图4-3 CPU环境下不同生成长度的单Token推理时延分析
启用 KV Cache 缓存优化
未启用 KV Cache (O(N^2)重复计算)
单Token生成耗时 (ms/Token)
当前对话上下文序列长度 (Tokens)
10
20
30
40
50
60
70
80
50
100
150
200
250