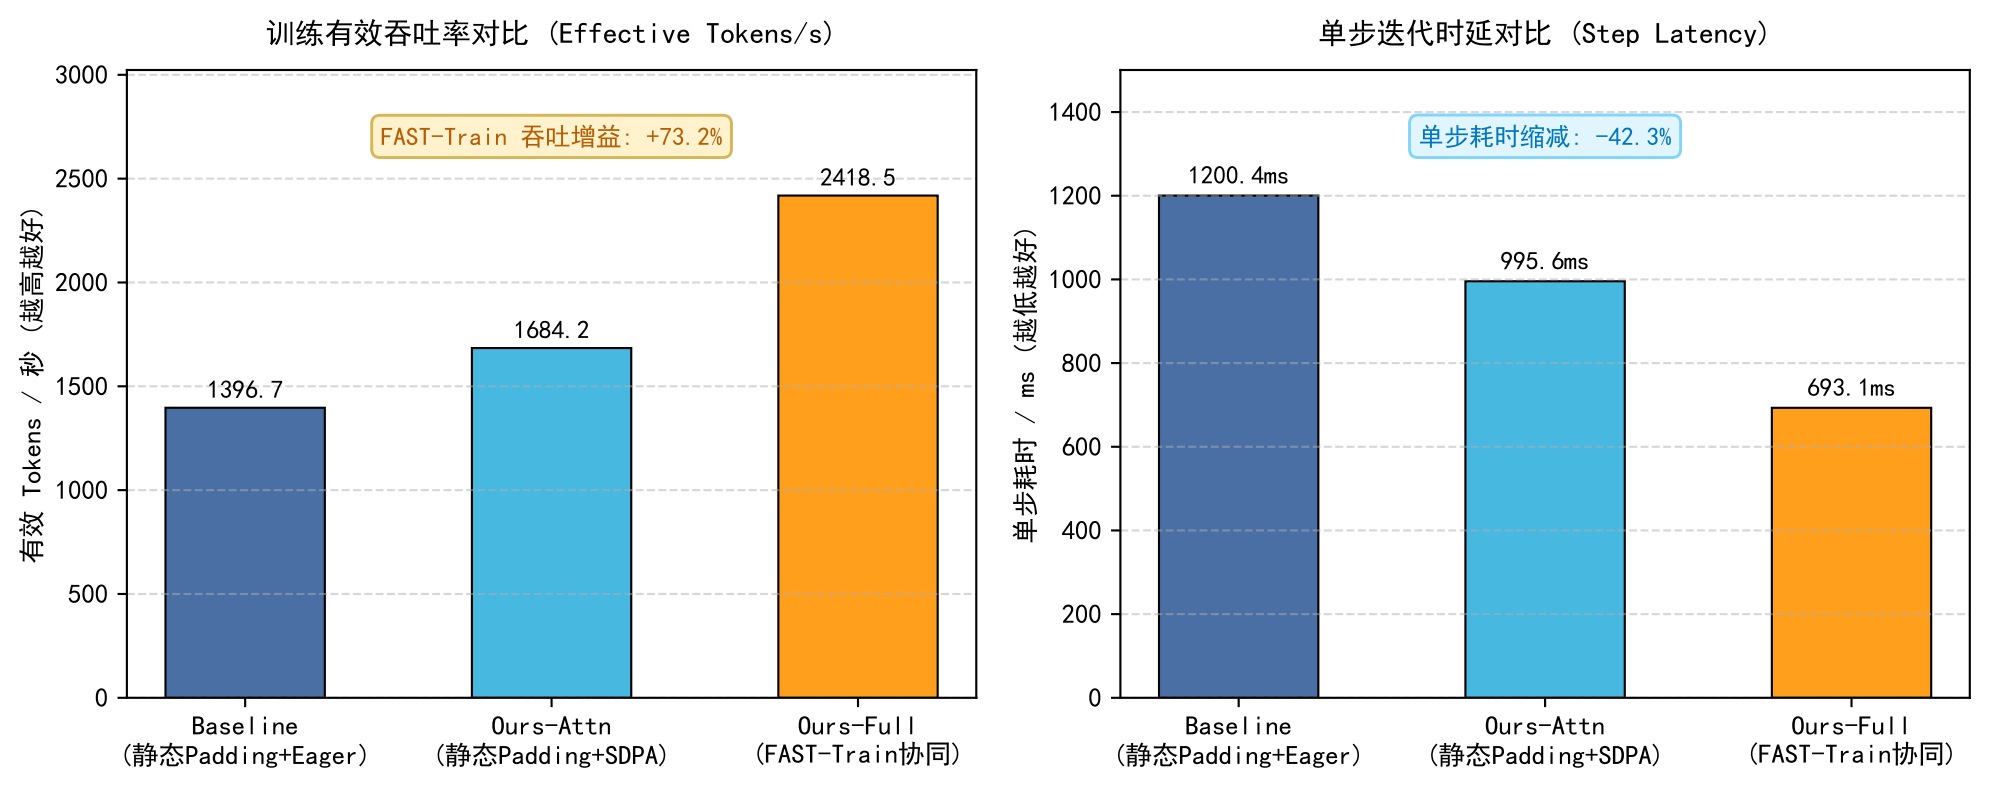
训练有效吞吐率对比（Effective Tokens/s）
FAST-Train 吞吐增益：+73.2%
有效 Tokens / 秒（越高越好）
3000
2500
2000
1500
1000
500
0
1396.7
1684.2
2418.5
Baseline
(静态Padding+Eager)
Ours-Attn
(静态Padding+SDPA)
Ours-Full
(FAST-Train协同)
单步迭代时延对比（Step Latency）
单步耗时缩减：-42.3%
单步耗时 / ms（越低越好）
1400
1200
1000
800
600
400
200
0
1200.4ms
995.6ms
693.1ms
Baseline
(静态Padding+Eager)
Ours-Attn
(静态Padding+SDPA)
Ours-Full
(FAST-Train协同)